ML-исследование больших данных телеметрии трафика реального ISP: CESNET – TimeSeries24 (dataset 130 GB / pub. Feb.2025)

OTUS ML.Advanced Курсовой Проект

Александр Севастьянов (Saint-Sanych)

Вызовы работы с реальными данными сетей, проклятие Телеком-Биг-Даты (анти-Фишер)

- разреженность целевого подмножества данных – зерна эффекта слишком редки среди плевел повседневной рутины
- фактическое исследование ML-методов на сетях проводилось в отсутствие реальных данных, поэтому их эффективность и стат.значимость эффекта может быть переоценена
- хранение сырых данных, генерируемых телеком сетью нерентабельно (не банки!) – гарантии и проклятие «Фишера»
- за отсутствием широкого использования наблюдается забронзовевшее с годами низкое качество данных – во всем!
- хранение исторических данных оперативного управления сетями предполагает только разбор локальных инцидентов – выгрузить пласт данных за период невозможно
- карго-культом является любая западная практика, включая всю вертикаль под CDO – слоя данных нет, как нет пользователей и целей

Реальный оператор университетских сетей Чехии на 0.5 млн активных пользователей (в день)

275K активных IP-адресов (из 400K)

548 подсетей маршрутизации

283 организации

полная анонимизация id в данных

отфильтрован транзит трафика

280 суток подряд 10-мин. агрегатов

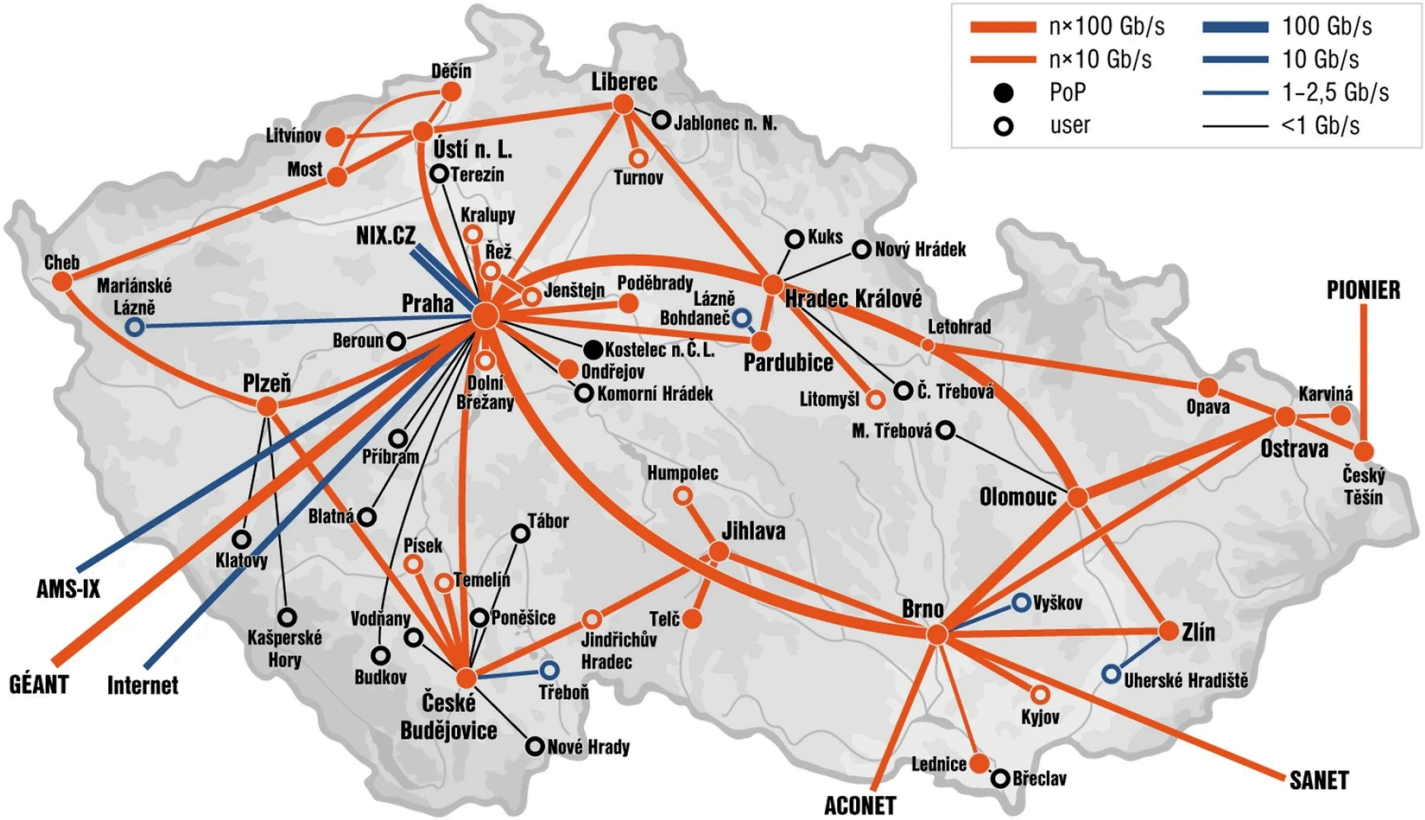

Сама организация сбора и методика пересчета данных – отдельный инженерный проект, поэтому данных такого качества нет у наших операторов

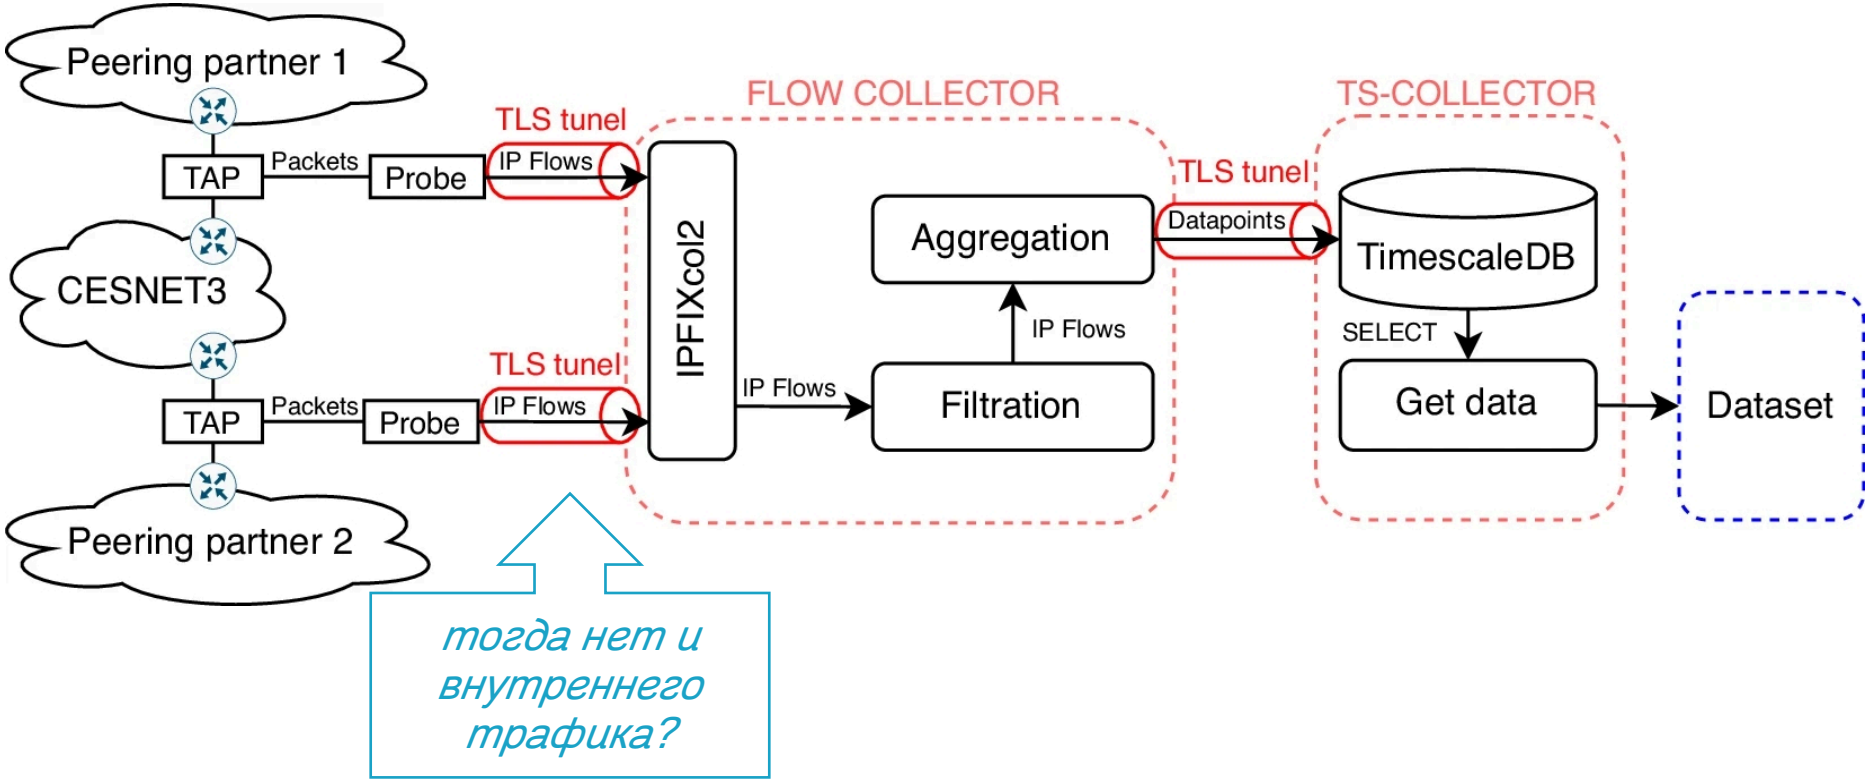

Данные телеметрии включают четыре группы и три уровня и три врем.интервала агрегации:

- ***Simple volumetric metrics:*** the number of IP flows, the number of packets, and the transmitted data size (i.e. number of bytes)
- ***Unique volumetric metrics:*** the number of unique destination IP addresses, the number of unique destination Autonomous System Numbers (ASNs), and the number of unique destination transport layer ports.
- ***Ratios metrics:*** the ratio of UDP/TCP packets, the ratio of UDP/TCP transmitted data size, the direction ratio of packets, and the direction ratio of transmitted data size
- ***Average metrics:*** the average flow duration, and the average Time To Live

Уровни (снизу вверх): отдельный **IP-address** -> routing-**subnet** -> **institution**
(за исключением 4х подсетей - делятся парой разных организаций каждая)

Интервалы: 10 минут (базовый) -> 1 час (агрегат) -> 1 сутки (агрегат)

EDA иерархических взаимосвязей субъектов

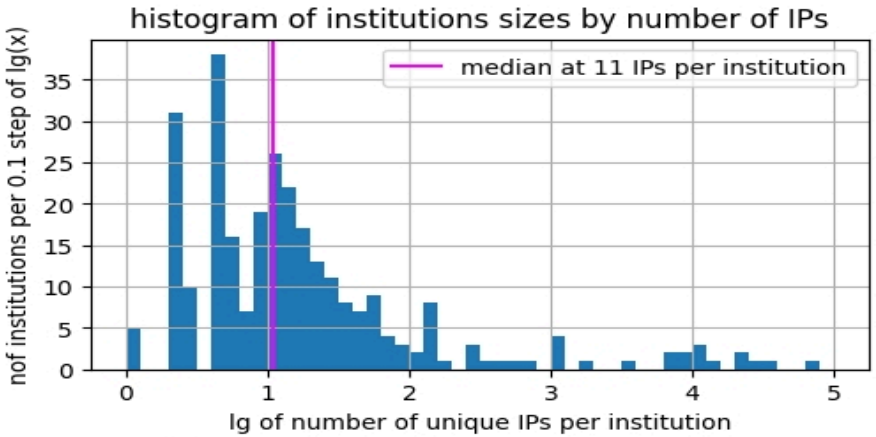

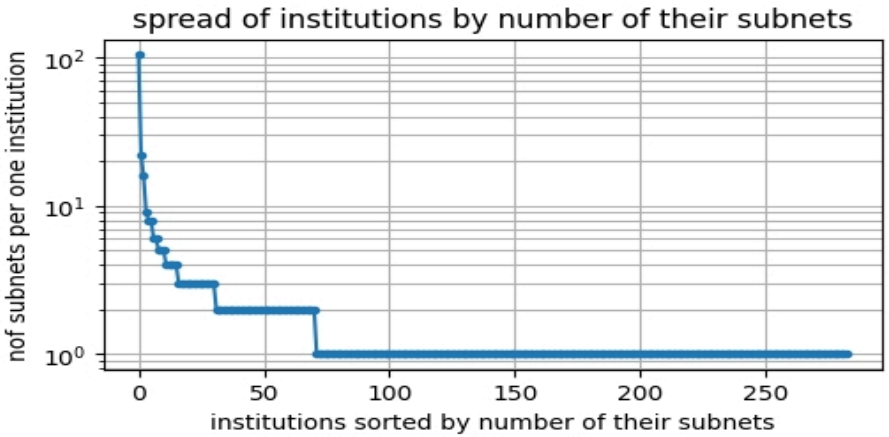

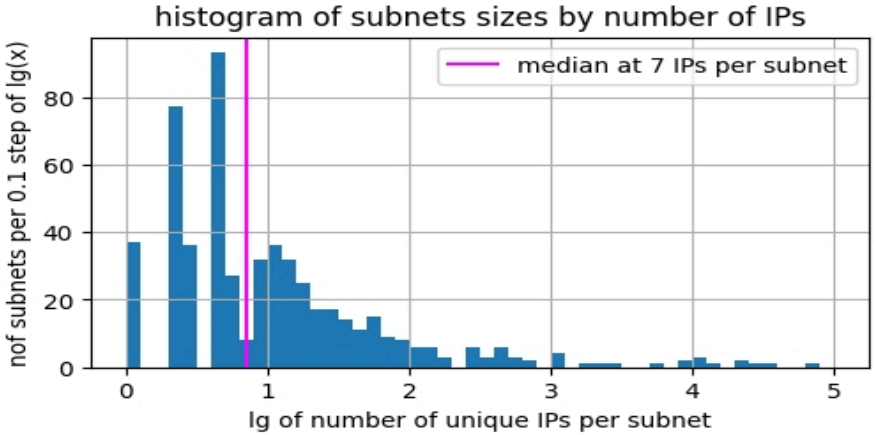

some observations:

although anonymization used sequential numbers as IDs,
many of them are missing for IPs and few for institutions,
may be due to filtering of transit traffic and of silent IPs;

most of 283 institutions have 1-3 subnets,
and only 3 institutions have more than 10,
of which just one has more than 100 subnets;

typical subnet size being 7 IPs,
typical institution size being 11 IPs,
but only 1% of IPs belong to these typical;

only 4 subnets are shared (between 2 institutions each).

А есть ли там вообще аномалии?
По-видимому, авторы датасета также были обеспокоены этим вопросом – частая картина:

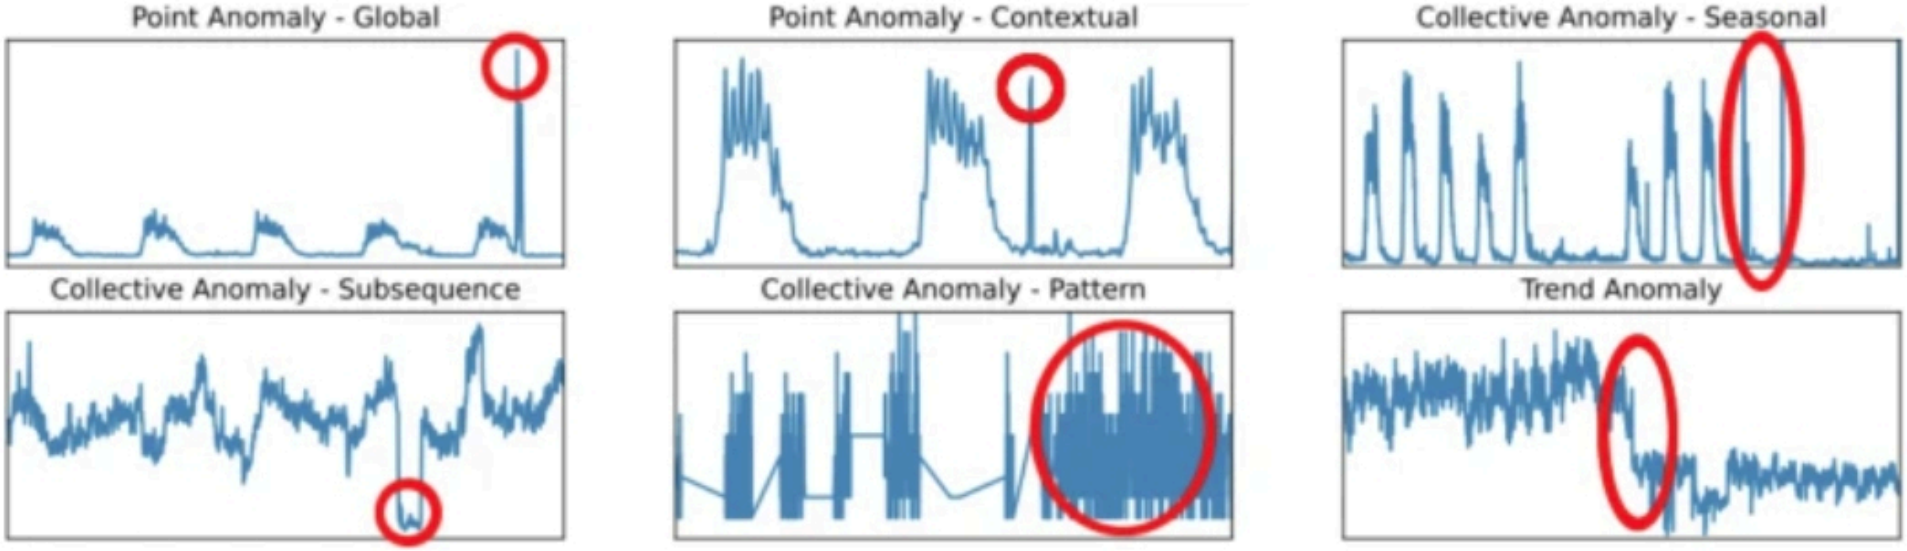

А вот с прикладным кейсом не очень – detected anomaly on IP address ID 1367 identified as DoS by CESNET experts

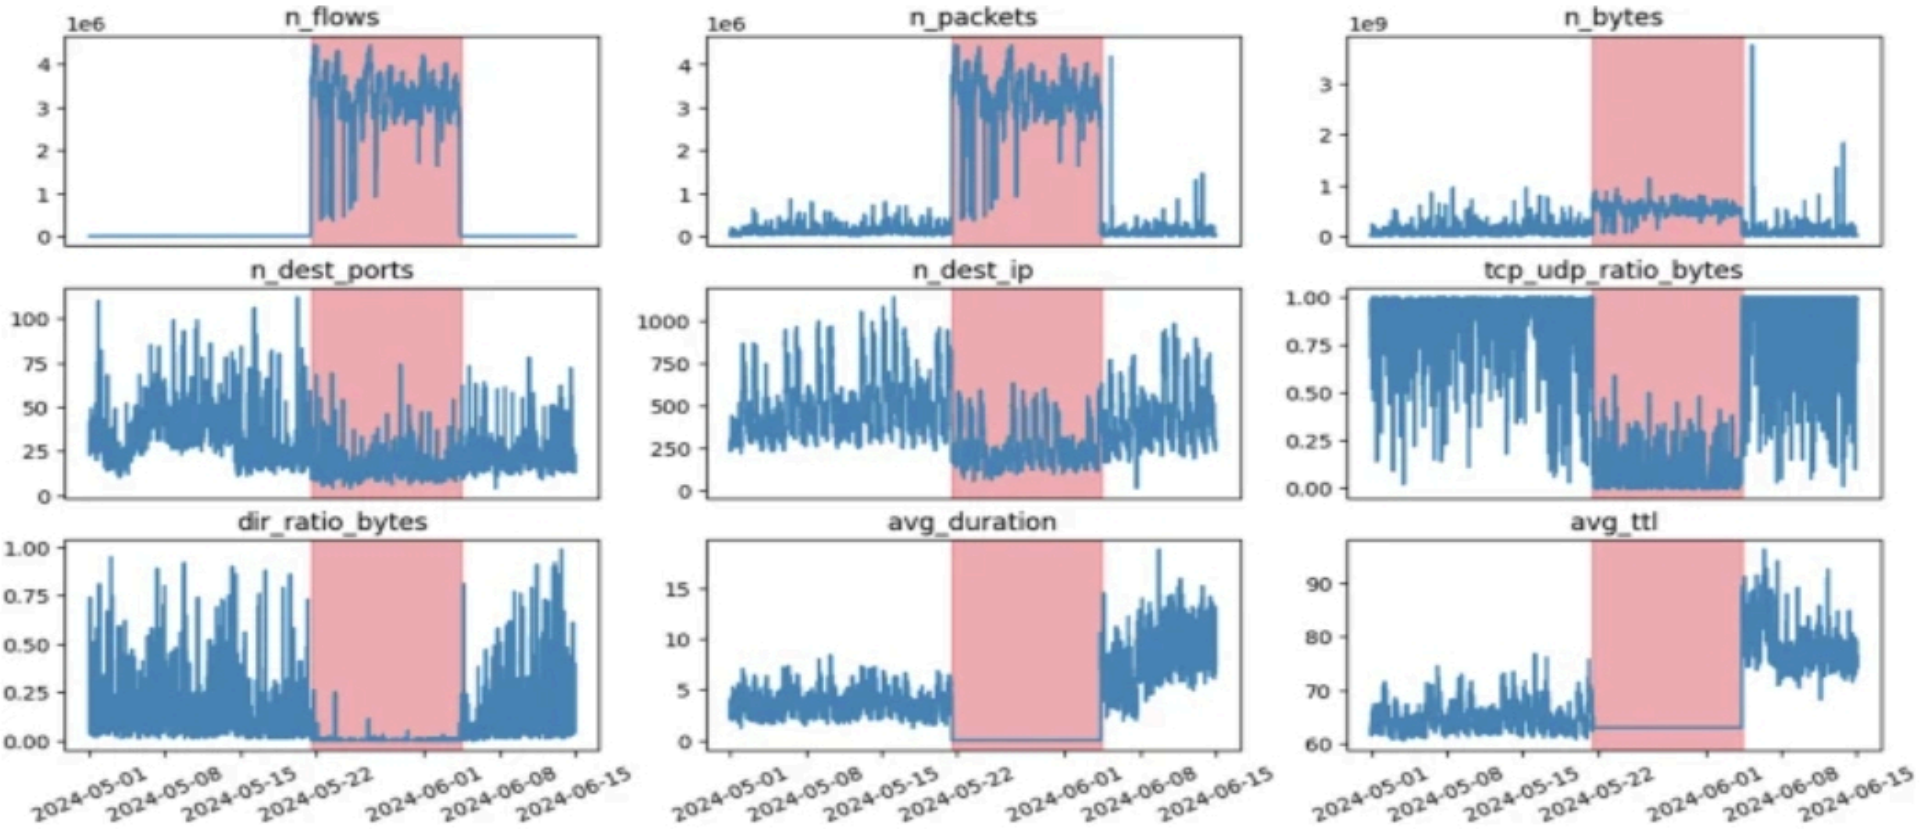

У нас нет возможности обсуждать кейсы с экспертами CESNET, поэтому определять инцидент будем сами

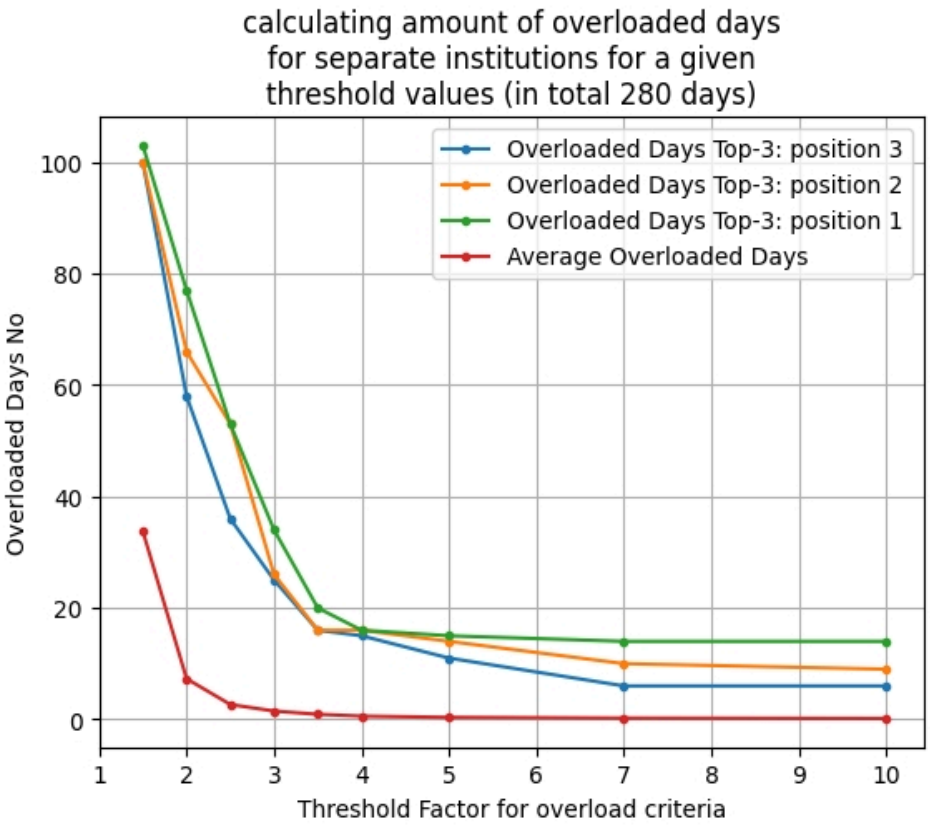

- сперва выберем уровень агрегации с данными которого будем работать – institutions
- теперь выберем естественный параметр, запредельные значения которого будем трактовать как инцидент – n_flows (кол-во сессий)
- организации разного размера, поэтому порог относительный – фактор превышения среднего уровня по данному институту
- подбираем фактор порога так, чтобы событие было редким для всей сети, но у топ-пары доля редкого класса была выше 15%

Посмотрим как во времени распределены проблемы top-3 лидеров по превышению дневной нагрузки

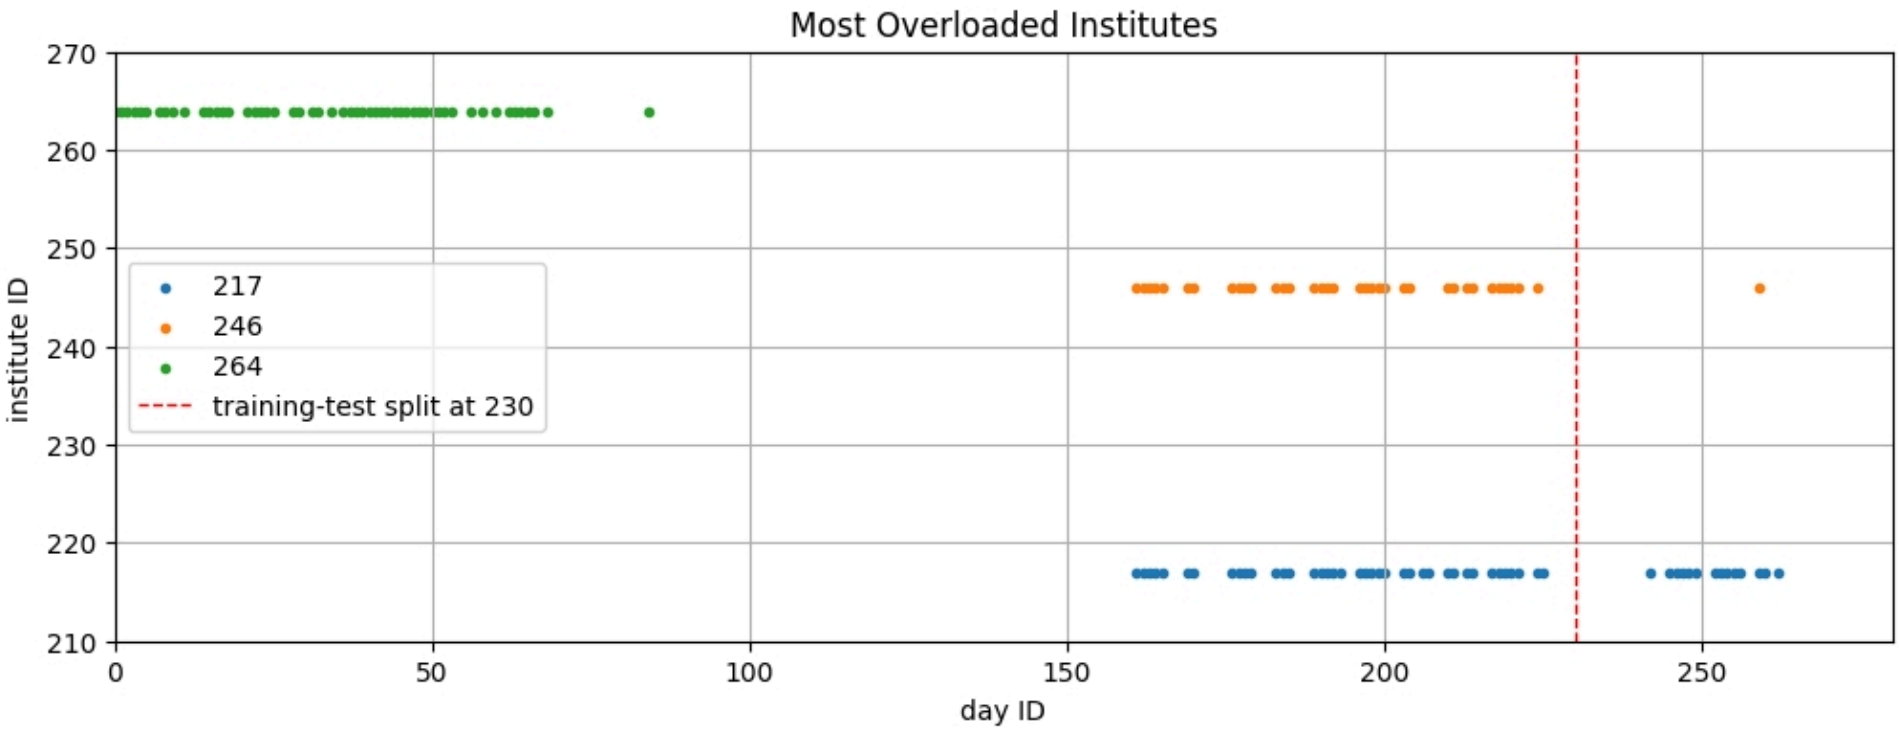

Zoom на 217 номере – идеальный кандидат на цель предсказания ML-моделью с естественным разбиением на train – test по времени, однако велика автокорреляция (и риск вырождения модели), поэтому из предикторов придется исключить 217, а также и 246 – тут риск обратного эффекта

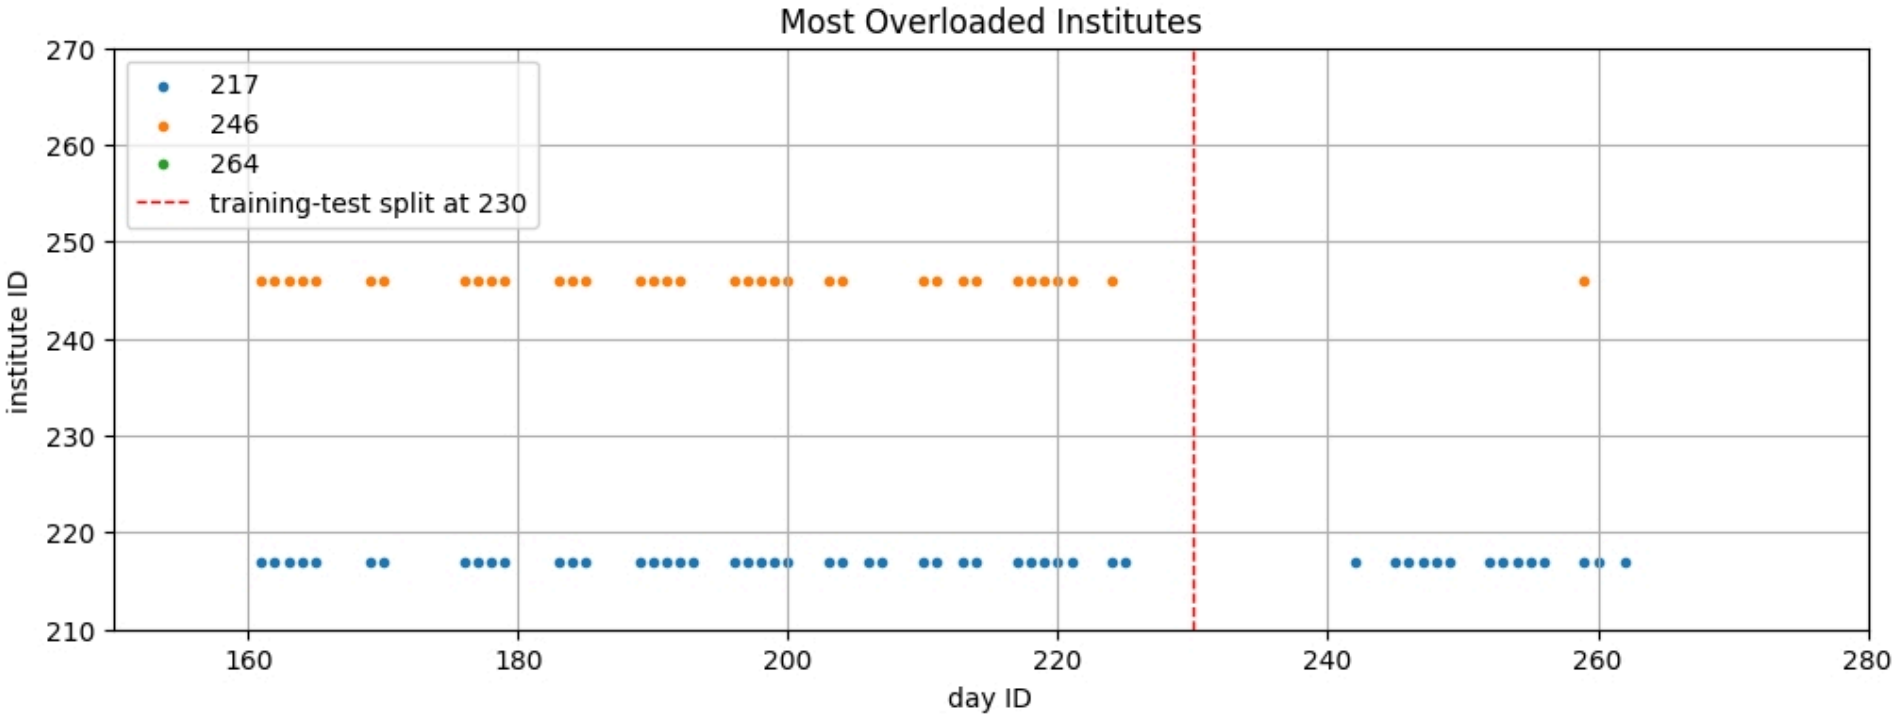

Итак, формулировка ML-задачи – проверим, действительно, ли сеть связна!

- собрать датасет с 1-2 недельным окном данных и шагом 1 сутки на всех организациях, кроме 217 и 246, обучить модель для предсказания:
- датасет для подавления автокорреляционных зависимостей зашаффлить
- если останется, попробовать pyTorch NN модель с выделением организаций в измерение каналов

- в качестве разметки использовать overload статус организации 217 по пороговому фактору 2.5 от средней нагрузки
- для проверки точности выделить все данные с 230-ого таймстемпа в валидационную выборку
- предсказывать с горизонтом от окна предикторов в 1 день, если пойдет ОК, пробовать 2 и 3