

ML-исследование больших данных
телеметрии трафика реального ISP:
CESNET – TimeSeries24
(dataset 130 GB / pub. Feb.2025)

OTUS ML.Advanced Курсовой Проект

Александр Севастьянов (Saint-Sanych)

Вызовы работы с реальными данными сетей, проклятие Телеком-Биг-Даты (анти-Фишер)

у всех так:

- разреженность целевого подмножества данных – зерна эффекта слишком редки среди плевел повседневной рутины
- фактическое исследование ML-методов на сетях проводилось в отсутствие реальных данных, поэтому их эффективность и стат.значимость эффекта может быть переоценена
- хранение сырых данных, генерируемых телеком сетью нерентабельно (не банки!) – гарантии и проклятие «Фишера»

у нас так:

- за отсутствием широкого использования наблюдается забронзовевшее с годами низкое качество данных – во всем!
- хранение исторических данных оперативного управления сетями предполагает только разбор локальных инцидентов – выгрузить пласт данных за период невозможно
- карго-культом является любая западная практика, включая всю вертикаль под CDO – слоя данных нет, как нет пользователей и целей

Реальный оператор университетских сетей Чехии на 0.5 млн активных пользователей (в день)

275K активных IP-адресов (из 400K)


548 подсетей маршрутизации

283 организации

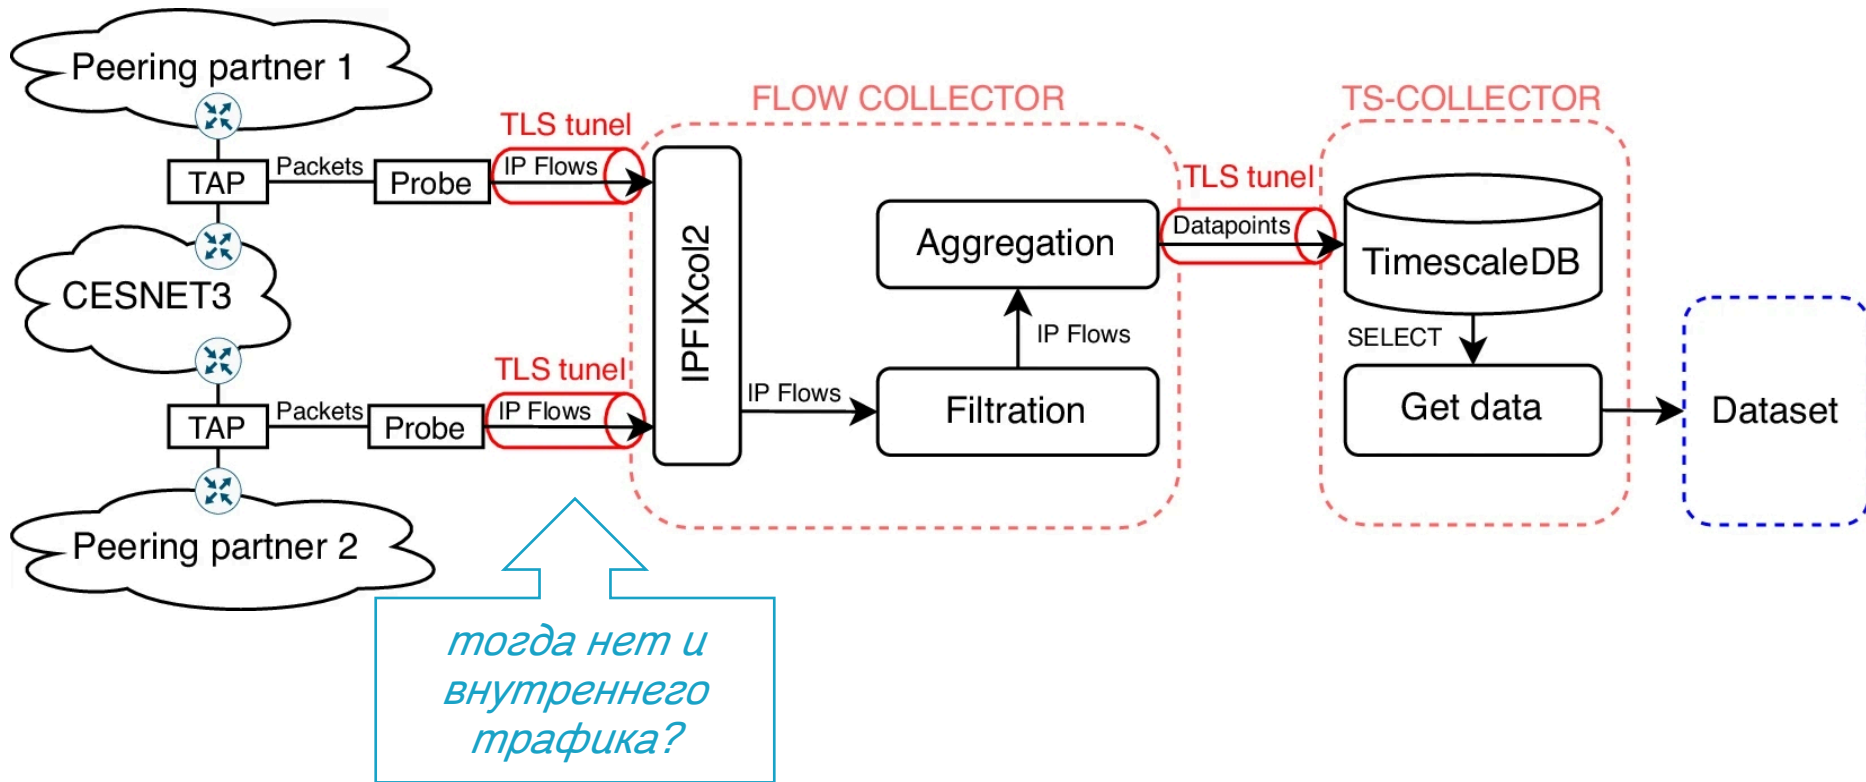
полная анонимизация id в данных

отфильтрован транзит трафика

280 суток подряд
10-мин. агрегатов



Сама организация сбора и методика пересчета данных – отдельный инженерный проект, поэтому данных такого качества нет у наших операторов






Данные телеметрии включают четыре группы и три уровня и три врем.интервала агрегации:

- ***Simple volumetric metrics:*** the number of IP flows, the number of packets, and the transmitted data size (i.e. number of bytes)
- ***Unique volumetric metrics:*** the number of unique destination IP addresses, the number of unique destination Autonomous System Numbers (ASNs), and the number of unique destination transport layer ports.
- ***Ratios metrics:*** the ratio of UDP/TCP packets, the ratio of UDP/TCP transmitted data size, the direction ratio of packets, and the direction ratio of transmitted data size
- ***Average metrics:*** the average flow duration, and the average Time To Live

Уровни (снизу вверх): отдельный **IP-address** -> **routing-subnet** -> **institution**
(за исключением 4х подсетей - делятся парой разных организаций каждая)

Интервалы: 10 минут (базовый) -> 1 час (агрегат) -> 1 сутки (агрегат)

EDA иерархических взаимосвязей субъектов



some observations:

although anonymization used sequential numbers as IDs, many of them are missing for IPs and few for institutions, may be due to filtering of transit traffic and of silent IPs;


most of 283 institutions have 1-3 subnets, and only 3 institutions have more than 10, of which just one has more than 100 subnets;

typical subnet size being 7 IPs, typical institution size being 11 IPs, but only 1% of IPs belong to these typical;

only 4 subnets are shared (between 2 institutions each).

А есть ли там вообще аномалии?
По-видимому, авторы датасета также были
обеспокоены этим вопросом – частая картина:


Point Anomaly - Global




Collective Anomaly - Subsequence




Point Anomaly - Contextual



Collective Anomaly - Pattern




Collective Anomaly - Seasonal



Trend Anomaly




А вот с прикладным кейсом не очень – detected anomaly on IP address ID 1367 identified as DoS by CESNET experts




У нас нет возможности обсуждать кейсы с экспертами CESNET, поэтому определять инцидент будем сами

calculating amount of overloaded days
for separate institutions for a given
threshold values (in total 280 days)




- сперва выберем уровень агрегации с данными которого будем работать – institutions
- теперь выберем естественный параметр, запредельные значения которого будем трактовать как инцидент – n_flows (кол-во сессий)
- организации разного размера, поэтому порог относительный – фактор превышения среднего уровня по данному институту
- подбираем фактор порога так, чтобы событие было редким для всей сети, но у топ-пары доля редкого класса была выше 15%

Посмотрим как во времени распределены проблемы top-3 лидеров по превышению дневной нагрузки



Zoom на 217 номере – идеальный кандидат на цель предсказания ML-моделью с естественным разбиением на train – test по времени, однако велика автокорреляция (и риск вырождения модели), поэтому из предикторов придется исключить 217, а также и 246 – тут риск обратного эффекта



Итак, формулировка ML-задачи – проверим, действительно, ли сеть связна!

- будем обучать модель, предсказывающую по скользящему окну (недельному) появление проблем через горизонт в один день
- пример: на вход модели идут данные со среды по вторник, предсказываем на них наличие проблем у 217 организации в ближайшую среду
- исследуем гридом вариации методов предобработки, ширину окна и глубину горизонта



- в качестве разметки используем overload статус организации 217 по пороговому фактору 2.5 от ее же средней нагрузки за 8 месяцев
- для контроля переобучения выделяем в тестовую выборку все данные с 230-ого (из 280) – последние 50 дней данных
- разные модели попробовали, но однозначный лидер Histogram Gradient Boosting Classifier (HGB) – нет смысла включать в грид


Так выглядят плоские (до сборки по окну и сжатия) данные

id_time	day_of_week	is_working_day	n_flows_0	n_packets_0	n_bytes_0	std_n_dest_ip_0	std_n_dest_ports_0	tcp_udp_ratio_packets_0
0	0	1	17967588.0	2.009822e+09	1.937482e+12	96.12	63.32	0.76
1	1	1	17222782.0	2.063504e+09	2.003213e+12	95.48	132.03	0.76
2	2	1	19697341.0	2.458140e+09	2.431213e+12	100.91	154.51	0.76
3	3	1	19702256.0	2.321789e+09	2.273312e+12	99.45	139.36	0.76
4	4	1	17396165.0	2.059123e+09	2.007808e+12	86.80	134.48	0.77
...	...	...	...	...	...	...	...	...
275	2	1	10660088.0	1.183226e+09	1.156170e+12	66.47	59.81	0.74
276	3	1	11555928.0	1.020931e+09	9.741181e+11	76.87	176.64	0.74
277	4	1	11042880.0	1.008126e+09	9.641151e+11	66.38	88.52	0.74
278	5	0	9182379.0	1.108790e+09	1.134578e+12	57.64	52.35	0.75
279	6	0	9054978.0	1.070795e+09	1.094385e+12	58.38	56.45	0.75

ws × 2541 columns

n_bytes_284	std_n_dest_ip_284	std_n_dest_ports_284	tcp_udp_ratio_packets_284	dir_ratio_packets_284	avg_duration_284	avg_ttl_284
1115958.0	36.05	2.05	0.46	0.47	3.43	207.42
1061740.0	33.25	1.78	0.45	0.47	3.57	210.09
1294795.0	40.28	2.07	0.47	0.45	3.53	210.00
1259480.0	39.80	1.91	0.43	0.45	3.55	208.37
1324206.0	39.66	2.04	0.44	0.43	3.60	208.56

Число колонок увеличивается еще в 7 раз при сборке оконного датасета – получаем 17.5K свойств при длине обучающей выборки всего в $230 - 8 = 222$ объекта – нужно снижение размерности – графики SVD/PCA позволяют оставить только $20-30 * 7 = 140-210$ признаков



Поиск гридом лучшего варианта предобработки и окна

		accuracy	roc-auc	precision	recall	f1
preprocessing	post_window					
unscaled	7	0.82	0.82	0.73	0.57	0.64
scaled	7	0.82	0.82	0.73	0.57	0.64
	14	0.64	0.71	0.42	0.71	0.53
unscaled	14	0.64	0.71	0.42	0.71	0.53
svd	14	0.70	0.73	0.46	0.43	0.44
pca	14	0.74	0.79	0.57	0.29	0.38
svd	7	0.72	0.65	0.50	0.21	0.30
pca	7	0.72	0.68	0.50	0.07	0.12
svd	3	0.72	0.65	0.50	0.07	0.12
pca	3	0.70	0.53	0.33	0.07	0.12
scaled	3	0.60	0.43	0.12	0.07	0.09
unscaled	3	0.60	0.43	0.12	0.07	0.09

4 вида предобработки:

- оставляем масштаб
- нормирование столб.
- PCA
- SVD

HGB-модель не чувствительна к нормализации, но теряет точность при линейном уменьшении размерности (PCA, SVD)

Так как гистограммно-перцентильный подход лучше нормализует данные, чем линейные преобразования

на обучающих данных:

	pred_0	pred_1
actual_0	183	0
actual_1	0	39


матрица конфликтов:

	pred_0	pred_1
actual_0	TN	FP
actual_1	FN	TP

на тестовых данных:


	pred_0	pred_1
actual_0	33	3
actual_1	6	8

model hits on test (not seen and future) data - prediction horizon 1 day on the 1 week history of all network



горизонт предсказания довольно глубокий: до 1 недели

Model Performance by Horizon



Выводы:

Первые 4 дня горизонта точность стабильная без деградации, затем потихоньку начинает деградировать, но тоже не быстро

Несмотря на очевидное переобучение, из-за сильного дисбаланса размерности фич (9 унитарных фич для 283 организаций и 7 дней окна), предсказательная сила модели весьма велика на полностью новых данных, взятых из будущего по отношению к периоду обучающих данных

Заключение по проекту

- исследованы особенности работы с биг-датой реального интернет-провайдера (телеком-оператора)
- удалось сформулировать критерии поиска в данных типичной проблемы с перегрузкой сети по новым сессиям и проведена локализация данных
- исследована возможность предсказания с горизонтом до 4 дней проблем в одной организации на основе недельных данных измерений по всей сети (283 организации)
- весь код тут:
https://github.com/SanSanychSeva/OTUS_ML_Adv_GradProj_SaintSanych_v1
- официальная ссылка на использованный датасет: Koumar, J., Hynek, K., Čejka, T. *et al.* CESNET-TimeSeries24: Time Series Dataset for Network Traffic Anomaly Detection and Forecasting. *Sci Data* **12**, 338 (2025).
<https://doi.org/10.1038/s41597-025-04603-x>